

VERSION 1.1
26 JUNI 2024



[PENGGALIAN DATA]

MODUL 4 - Regression and Classification in
Different Dataset Types

DISUSUN OLEH:
ALVIYA LAELA LESTARI
KIARA AZZAHRA

DIAUDIT OLEH:
YUFIS AZHAR, S.KOM, M.KOM

LAB. INFORMATIKA
UNIVERSITAS MUHAMMADIYAH MALANG

[PENGALIAN DATA]

PERSIAPAN MATERI

Mahasiswa mempelajari perbedaan jenis-jenis data, klasifikasi dan regresi

TUJUAN

1. Mahasiswa mampu memahami algoritma klasifikasi untuk setiap jenis data
2. Mahasiswa mampu memahami algoritma regresi untuk setiap jenis data

PERSIAPAN SOFTWARE/APLIKASI

1. **HARDWARE**
Komputer / Laptop
2. **SOFTWARE (Pilih salah satu)**
Visual Studio Code, Google Collaboratory, PyCharm, Jupyter Notebook

A. Classification and Regression

Klasifikasi (classification) sering digunakan dalam menganalisis data untuk mengelompokkan data ke dalam kategori tertentu berdasarkan karakteristik atau fitur yang dimiliki oleh sebuah data. Misalnya, sebuah bank dapat memutuskan apakah akan memberikan pinjaman kepada nasabah berdasarkan riwayat kreditnya.

Sedangkan **regresi (regression)** sering digunakan untuk memprediksi nilai atau mengestimasi tren. Model regresi mencoba memahami hubungan antara variabel independen (fitur) dan variabel dependen (target) agar bisa membuat prediksi berdasarkan data baru. Contohnya, memprediksi harga rumah dengan menentukan fitur seperti luas rumah, jumlah kamar, dan lokasi.

Aspek	Klasifikasi	Regresi
Output	Kategori (diskrit)	Nilai Kontinu (Angka)
Contoh Output	"Ya" atau "Tidak", 0 atau 1	\$100, 25.5, 3,200
Tujuan	Mengelompokkan data	Memprediksi nilai

Untuk melakukan klasifikasi maupun regresi data, berikut adalah tahap yang umum dilakukan sebelum data diolah oleh algoritma:

1. **Feature Selection**

Langkah pertama dalam regresi adalah menentukan variabel target (variabel dependen), yaitu nilai yang ingin diprediksi, serta variabel fitur (variabel independen), yaitu data yang digunakan untuk membuat prediksi.

2. **Preprocessing Data**

Langkah kedua adalah melakukan pembersihan data (*data cleaning*) dan transformasi agar data siap digunakan oleh model

3. **Splitting Data**

Proses ini dikenal dengan *splitting data*, yaitu dengan membagi data menjadi tiga yaitu *train* (data pelatihan), *test* (data uji), *validation* (data validasi). Namun, biasanya data bisa juga dibagi menjadi dua yaitu *train* dan *test* dengan rasio seperti 80:20 atau 70:30. Data validation sering digunakan dalam proses *hyperparameter tuning* untuk memilih parameter terbaik seperti tingkat regulasi atau jenis optimisasi.

4. **Menentukan model/algoritma** yang akan digunakan

5. **Training Model**

Setelah menentukan model yang akan digunakan, model dilatih menggunakan data pelatihan (*data train*) untuk mempelajari hubungan antara fitur dan target dengan melibatkan algoritma optimasi untuk meminimalkan kesalahan prediksi.

6. **Evaluasi Model**

Model yang sudah dilatih, diuji menggunakan data uji (*data test*) untuk mengevaluasi performanya. Beberapa metrik evaluasi yang sering digunakan untuk **klasifikasi** adalah:

- **Accuracy:** Proporsi prediksi benar dari seluruh prediksi.
- **Precision:** Mengukur proporsi prediksi positif yang benar.
- **Recall:** Mengukur proporsi data positif yang berhasil diidentifikasi dengan benar.
- **F1-Score:** Harmonik rata-rata antara Precision dan Recall.

Sedangkan metrik evaluasi **regresi** yang umum digunakan adalah:

- **Mean Absolute Error (MAE)**: Rata-rata kesalahan absolut.
- **Mean Squared Error (MSE)**: Rata-rata kuadrat kesalahan.
- **R-squared (R^2)**: Menunjukkan seberapa baik model menjelaskan variabilitas data.

B. Structured Data

Dataset yang memiliki struktur yang terorganisir dan format yang jelas disebut dengan **dataset terstruktur (structured dataset)**. Dataset yang terstruktur seringkali ditampilkan dalam bentuk tabel dengan baris dan kolom yang terdefinisi. Setiap baris merepresentasikan satu entitas atau observasi, sementara setiap kolom menunjukkan atribut atau karakteristik yang dimiliki oleh entitas tersebut. Misalnya, dalam dataset penjualan, setiap baris dapat merepresentasikan transaksi tertentu, sedangkan kolom mencakup informasi seperti nama pelanggan, produk yang dibeli, transaksi, tanggal dan lokasi.

Dataset yang terstruktur memudahkan proses eksplorasi dan analisis data karena strukturnya yang rapi. Kita dapat dengan mudah melakukan agregasi, perhitungan statistik, atau visualisasi data untuk menemukan pola atau tren tertentu. Selain itu, dataset terstruktur juga sangat kompatibel dengan berbagai alat analisis seperti Excel, SQL, atau bahasa pemrograman seperti Python dan R, yang memiliki fitur bawaan untuk mengolah data tabular.

1. Data Tabular


Data tabular merupakan data yang dapat ditampilkan dalam bentuk tabel dengan baris dan kolom. Penggunaan data tabular sering digunakan pada bidang kesehatan, bisnis perusahaan, pendidikan, dan lainnya. Selain bentuk data yang terorganisir dan memudahkan untuk melakukan analisa, data tabular dapat membantu data analyst untuk menemukan pola dalam data, mendukung pengambilan keputusan berbasis data dan mudah dianalisis menggunakan software analisis data seperti Excel atau software Business Intelligence. Sebagai contoh, perusahaan dapat menganalisis data gaji

karyawan untuk memahami perbedaan gaji antar jabatan atau tren penggajian secara keseluruhan.

a. Feature Selection Data Tabular

Feature Selection adalah proses pemilihan subset fitur (variabel, atribut) yang paling relevan dari dataset untuk digunakan dalam pembuatan model. Dalam konteks data tabular, tujuan dari feature selection adalah untuk mengidentifikasi dan memilih kolom (fitur) yang paling berkontribusi terhadap variabel target atau hasil yang ingin diprediksi, sambil menghilangkan fitur yang redundan atau tidak relevan. Berikut beberapa cara untuk menentukan fitur pada data tabular:

- Manual (Domain Knowledge) : Kita akan menentukan fitur dari sebuah dataset berdasarkan pengetahuan kita sendiri. Contoh seperti dataset prediksi harga rumah diatas, kita dapat menentukan fitur-fitur tersebut berdasarkan pengetahuan kita tentang properti.
- Statistik (Correlation) : Mengukur korelasi antara fitur dengan target. Jika korelasinya kecil atau mendekati nol, fitur tersebut mungkin tidak relevan. Gunakan *correlation heatmap* untuk mempermudah kita mengetahui korelasi antar fitur.



- Automated Methods: mungkin akan sedikit rumit, tapi kita juga dapat menentukan fitur dengan menggunakan algoritma yang sudah disediakan pada library seperti scikit-learn yaitu *Recursive Feature Elimination* (RFE) atau *Lasso Regression* yang akan secara otomatis menentukan fitur yang penting saja.

Contoh, kita memiliki sebuah dataset tentang perumahan di Araya yang akan diolah untuk memprediksi harga rumah. Dari dataset tersebut, kita akan menentukan fitur yang relevan dengan harga rumah. Misalnya :

- Luas rumah, semakin luas sebuah rumah, maka harga akan semakin mahal
- Jumlah kamar tidur/kamar mandi
- Lokasi rumah
- View (pemandangan), biasanya semakin indah pemandangan dapat berpengaruh terhadap harga penjualan
- Kondisi rumah, dsb.

Lalu, contoh fitur yang kurang relevan seperti apa? contoh, warna cat rumah, jumlah jendela, nomor rumah dsb. Berikut adalah tujuan dari *feature selection* :

- Menghilangkan fitur yang tidak relevan atau berisik dapat meningkatkan kinerja model.
- Mengurangi kompleksitas model dengan memilih hanya fitur yang paling penting dapat mengurangi risiko **overfitting** (model terlalu mempelajari/cenderung dengan dataset latihan sehingga gagal membuat prediksi pada data baru)
- Model yang lebih sederhana dengan fitur yang lebih sedikit cenderung lebih cepat dalam proses pelatihan.
- Model dengan fitur yang lebih sedikit lebih mudah untuk diinterpretasikan dan dipahami.

b. Algoritma Klasifikasi Data Tabular

Berikut beberapa contoh metode pendekatan yang sering digunakan untuk klasifikasi data tabular.

- **Random Forest:** merupakan kumpulan (*ensemble*) dari banyak decision tree. Hasil akhir diputuskan berdasarkan voting dari setiap tree. Model ini tentu lebih akurat dibandingkan decision tree.
- **Naive Bayes:** merupakan model probabilistik yang menggunakan teorema Bayes dengan asumsi bahwa semua fitur saling independen. Model ini juga termasuk model yang cepat dan sederhana, cocok untuk data dengan fitur kategorikal atau teks.
- **Decision Tree:** model yang memecah data ke dalam cabang-cabang berdasarkan kondisi tertentu (seperti if-else). Contohnya, model dapat memutuskan apakah seorang pelanggan akan membeli produk dengan melihat histori pembelian mereka.
- **K-Nearest Neighbors (KNN):** bekerja dengan mencari "tetangga terdekat" (*nearest neighbors*) dari data baru untuk menentukan kategorinya.
- **Support Vector Machine (SVM):** bekerja dengan memisahkan data ke dalam kategori dengan mencari *hyperplane* terbaik yang memaksimalkan margin antara kelas-kelas.

c. Algoritma Regresi Data Tabular

Regresi adalah teknik statistik yang digunakan untuk memodelkan dan menganalisis

hubungan antara variabel dependen (target) dan satu atau lebih variabel independen (fitur). Contoh model regresi meliputi:

- **Regresi Linear:** Untuk hubungan linear antara fitur dan target.
- **Regresi Ridge/Lasso:** Untuk mengatasi masalah *overfitting* dengan menambahkan regulasi.
- **Regresi Polynomial:** Untuk menangani hubungan non-linear.

2. Data Time Series

Tahun	Pengangguran Terbuka	Jumlah Penduduk	Upah Minimum Provinsi	Pertumbuhan Ekonomi
	Y	X1	X2	X3
1998	5,46	18,98	11,92	-13,13
1999	6,36	19,00	12,07	0,79
2000	6,08	19,02	12,29	4,92
2001	8,10	19,03	12,58	3,64
2002	9,06	19,05	12,80	4,50
2003	9,67	19,07	12,94	4,78
2004	9,86	19,08	13,04	5,03
2005	11,24	19,10	13,14	5,69
2006	10,28	19,11	13,31	5,50
2007	9,11	19,13	13,42	6,35
2008	8,39	19,14	13,52	6,01
2009	7,87	19,16	13,64	4,63
2010	7,14	19,17	13,72	6,22
2011	7,48	19,18	13,80	6,17
2012	6,13	19,20	13,90	6,03
2013	6,17	19,21	14,08	5,56
2014	5,94	19,22	14,28	5,02
2015	6,18	19,24	14,40	4,79
2016	5,61	19,25	14,51	5,02
2017	5,50	19,26	14,55	5,07
2018	5,34	19,28	14,64	5,06
2019	5,28	19,29	14,71	5,02

Data Time Series adalah data yang dikumpulkan dari waktu ke waktu dengan interval waktu yang teratur. Data ini sering digunakan khususnya pada bidang ekonomi, meteorologi dan pemrosesan sinyal. Dengan melihat data dari waktu ke waktu, kita dapat menemukan pola tren pada data, pola musiman dan variabilitas.

Jenis analisa yang sering digunakan pada data *time series* diantaranya:

- Curve Fitting** adalah teknik yang memanfaatkan fungsi matematika untuk memodelkan data time series. Dengan cara ini, hubungan antar variabel dalam data bisa dipahami lebih jelas.
- Classification** bertujuan untuk mengelompokkan data berdasarkan kriteria tertentu. Melalui metode ini, pola-pola dalam data dapat diidentifikasi dan dianalisis dengan lebih terstruktur.

c. Segmentation adalah proses membagi data time series menjadi beberapa sub-kategori berdasarkan kriteria tertentu. Pendekatan ini membantu mengungkap informasi atau karakteristik yang mungkin tidak terlihat langsung.

d. Descriptive Analysis

Descriptive analysis fokus pada menggambarkan pola dalam data time series. Analisis ini sangat berguna untuk memahami tren atau siklus musiman dalam data.

e. Forecasting

Forecasting membantu memprediksi pola data di masa depan berdasarkan data historis. Metodenya bisa berupa ekstrapolasi, algoritma machine learning, atau pendekatan seperti ARIMA (Autoregressive Integrated Moving Average).

f. Explanative Analysis

Explanative analysis lebih mendalam dibandingkan descriptive analysis karena tidak hanya menggambarkan pola, tetapi juga menjelaskan mengapa pola tersebut muncul. Analisis ini membutuhkan variabel tambahan di luar data untuk memberikan konteks terhadap pola yang ada.

g. Intervention Analysis

Intervention analysis mempelajari bagaimana sebuah intervensi, seperti perubahan kebijakan atau faktor eksternal lainnya, memengaruhi data time series.

h. Exploratory Analysis

Exploratory analysis bertujuan untuk memahami karakteristik mendasar dari data time series. Dengan analisis ini, kita bisa mengenali pola, memahami struktur data, dan menemukan anomali yang mungkin ada.

Ada beberapa metode yang umum digunakan untuk **menganalisis** jenis data ini. Berikut penjelasannya:

a. Metode Holt-Winters

Metode ini dikenal juga sebagai teknik pemulusan eksponensial. Holt-Winters digunakan untuk memprediksi data time series yang memiliki pola musiman.

Metode ini sangat cocok untuk analisis tren musiman jangka pendek karena kemampuannya menangkap fluktuasi pola yang berulang.

b. Metode Model ARIMA Box-Jenkins

ARIMA, singkatan dari *Autoregressive Integrated Moving Average*, adalah model yang dirancang untuk menganalisa dan memprediksi data time series dengan satu variabel. Model ini bekerja dengan baik pada data stasioner, yaitu data yang memiliki kovariansi dan variansi konstan sepanjang waktu.


c. Metode Model Multivariate Box-Jenkins

Berbeda dengan ARIMA, metode multivariat digunakan untuk menganalisis data time series dengan lebih dari satu variabel. Pendekatan ini memungkinkan kita memahami hubungan antar variabel dalam rentang waktu tertentu. Contohnya, model ini dapat membantu menganalisis hubungan antara penjualan sepatu dan kondisi cuaca, yang dipengaruhi oleh faktor waktu.

Metode pendekatan yang sering digunakan untuk regresi data time series diantaranya adalah *linear regression*, *bayesian linear regression*, *random forest regression* dan *nearest neighbors regression*. Untuk insight tentang regresi data time series, kita akan mempelajari metode *random forest regression* yang bisa kalian akses di notebook yang sudah disediakan diatas.

C. Unstructured Dataset

1. Data Teks



Data teks adalah jenis data tidak terstruktur yang terdiri dari urutan karakter berupa kata, kalimat atau paragraf. Data ini biasanya berasal dari berbagai sumber seperti dokumen, artikel, email, media sosial, atau komunikasi digital lainnya. Data teks biasanya tidak tersusun dalam format baris dan kolom. Contohnya, data yang berasal dari email atau media sosial hanya berupa paragraf teks yang sulit langsung dianalisis secara numerik. Oleh karena itu, diperlukan teknik khusus untuk mengubah data teks menjadi format yang lebih terstruktur seperti *Bag-of-Words* (BoW) atau *word embeddings* (Word2Vec, Glove, BERT).

Salah satu contoh analisis menggunakan data teks adalah *Sentiment Analysis*. Analisis ini digunakan untuk menentukan sentimen dari teks, apakah positif, negatif atau netral. Contoh pada kalimat "Film *interstellar* sangat bagus", hasil analisis sentimen adalah **positif**. Sedangkan pada kalimat. "Aku tidak peduli dengan praktikum" akan menghasilkan sentimen **negatif**. Algoritma machine learning untuk teks yang sering digunakan adalah [Naive Bayes](#), [SVM](#) atau [Random Forest](#) untuk mengklasifikasikan teks berdasarkan kategori.

A. Text Preprocessing

Text preprocessing adalah proses mengolah data teks mentah menjadi bentuk yang lebih terstruktur agar bisa diolah oleh algoritma. Text preprocessing merupakan langkah krusial dalam Natural Language Processing (NLP) karena data teks mentah biasanya mengandung banyak unsur yang tidak diperlukan atau mengganggu proses pembelajaran mesin. Berikut adalah tahapan-tahapan utama dalam text preprocessing:

1. Case Folding

Pada tahap ini, semua huruf pada teks akan diubah menjadi huruf kecil (lowercase) agar tidak ada perbedaan kapitalisasi

2. Data Cleaning

Sama seperti penjelasan pada modul 2, pada data teks akan dilakukan menghapus karakter yang tidak diperlukan seperti tanda baca, angka, HTML tags, URL, username (@user) hashtag (#) dan emoji. Contoh "Saya senang! 😊 @wooseok #bahagia" menjadi → "saya senang wooseok bahagia".

3. Tokenization

Tahap ini data teks akan dipecah menjadi per-kata, frasa bahkan karakter. Contoh pada kalimat "Pastikan kau temukan aku di garis terdepan" akan dipecah menjadi ['Pastikan', 'kau', 'temukan', 'aku', 'di', 'garis', 'terdepan'].

4. Stopwords Removal

Langkah ini hampir sama dengan tokenization tetapi, metode ini menghapus kata-kata umum yang tidak memberikan makna signifikan dalam analisis, seperti "dan", "di", "ke", "yang". Contoh pada kalimat "Pastikan kau temukan aku di garis terdepan" akan dipecah menjadi ['Pastikan', 'kau', 'temukan', 'aku', 'garis', 'terdepan'].

5. Stemming and Lemmatization

Selanjutnya, stemming merupakan proses kata-kata yang memiliki imbuhan akan diubah menjadi kata dasar. Contoh "belajar" menjadi "ajar".

Sedangkan lemmatization mengubah kata menjadi bentuk dasar sesuai konteks dengan mempertimbangkan kamus dan konteks kalimat. Contoh "belajar" tetap "belajar".

6. Padding/Truncating

Langkah ini adalah untuk menyeragamkan panjang teks. Padding akan menambahkan token khusus jika teks terlalu pendek dan truncating akan memotong teks jika terlalu panjang.

7. Text-to-Numeric Transformation

Mengubah teks menjadi format numerik yang bisa diproses oleh algoritma machine learning, seperti Bag-of-Words (BoW), encoding, atau TF-IDF.

a. Metode Bag-of-Words (BoW)

Metode ini akan merepresentasikan teks sebagai vektor dimana memberikan label vektor sekumpulan kata tanpa memperhatikan urutan kata. Contoh dari dua kalimat:

"Saya bertepuk sebelah tangan" dan "Saya bertepuk kedua tangan"


Kata	"Saya bertepuk sebelah tangan"	"Saya bertepuk kedua tangan"
Saya	1	1
bertepuk	1	1
sebelah	1	0
tangan	1	1
kedua	0	1

Setiap kalimat direpresentasikan sebagai vektor berdasarkan kemunculan kata-kata:

1. "Saya bertepuk sebelah tangan" → **[1, 1, 1, 1, 0]**
2. "Saya bertepuk kedua tangan" → **[1, 1, 0, 1, 1]**

Dengan BoW, hubungan antar kata tidak diperhatikan, sehingga kedua kalimat memiliki representasi berbeda meskipun strukturnya mirip.

b. Term Frequency-Inverse Document Frequency (TF-IDF)



Teknik ini digunakan untuk mengukur seberapa penting suatu kata dalam sebuah dokumen dengan mempertimbangkan **Term Frequency (TF)** dan **Inverse**

Document Frequency (IDF). TF akan menghitung seberapa sering kata itu muncul dalam satu dokumen, misalnya, kalian mempunyai artikel tentang diabetes. Jika kata “diabetes” muncul 5 kali dalam artikel tersebut, maka kata “diabetes” memiliki nilai TF yang lebih tinggi dalam artikel tersebut. Sedangkan, IDF akan menghitung seberapa jarang kata tersebut muncul di semua dokumen yang ada. Misalnya, kata “diabetes” mungkin muncul hampir di semua artikel kesehatan, tetapi kalau kata “retinopati” hanya muncul di beberapa artikel, berarti kata itu lebih langka dan nilai IDF-nya lebih tinggi.

c. Encoding

Tahap ini adalah proses mengubah kata menjadi representasi angka yang bisa dipahami model. Ada beberapa jenis encoding, yaitu:


- **Label Encoding:** mengubah kata menjadi angka berurutan
contoh: (kucing → 1, anjing → 2)
- **One-Hot Encoding:** mengubah kata menjadi vektor biner
contoh: (kucing → [1,0,0], anjing → [0,1,0])
- **Word Embedding:** mengubah kata menjadi vektor padat yang menyimpan makna semantik

B. Klasifikasi Teks Menggunakan ANN dan Naive Bayes

Terdapat banyak sekali algoritma yang bisa kita gunakan, tetapi untuk insight saja, mari kita pelajari sedikit tentang algoritma yang sering digunakan untuk klasifikasi data teks. **Neural Network** (NN) adalah jaringan syaraf tiruan yang terinspirasi dari model jaringan saraf pada otak manusia. Salah satu algoritma NN yang umum digunakan untuk klasifikasi teks adalah *Artificial Neural Network* (ANN) adalah proses di mana teks diubah menjadi bentuk numerik agar ANN dapat memahami dan menganalisisnya.

Kedua, klasifikasi teks menggunakan algoritma *Naive Bayes* adalah proses dimana menghitung kemungkinan suatu kelas berdasarkan data tertentu. Kelebihan dari algoritma ini adalah cepat, sederhana, dan bekerja baik untuk data teks dengan fitur besar.

2. Data Citra



Data citra adalah dataset yang berisi kumpulan gambar, representasi visual dalam bentuk pixel yang disimpan dalam format digital. Dalam konteks komputer dan pemrosesan digital, citra sering direpresentasikan sebagai grid dua dimensi pixel, di mana setiap pixel merupakan elemen dasar yang membentuk citra dan memiliki nilai yang menunjukkan aspek seperti intensitas cahaya atau warna. Dataset citra dalam jumlah besar bisa kalian dapatkan dari sumber seperti **ImageNet**, salah satu dataset paling terkenal dalam bidang *computer vision*. **ImageNet** adalah kumpulan data yang berisi jutaan gambar dengan anotasi label yang dikelompokkan ke dalam ribuan kategori. Dalam *data science* dan *machine learning*, data citra sering digunakan sebagai input untuk model yang dilatih untuk melakukan tugas-tugas seperti klasifikasi citra, deteksi objek, dan segmentasi citra.

A. Image Preprocessing

Sama halnya dengan teks, citra juga memiliki tahap penting sebelum diolah oleh algoritma yang akan kita gunakan klasifikasi, deteksi maupun segmentasi. **Image Preprocessing** adalah tahap yang wajib dilakukan untuk meningkatkan kualitas citra, mengurangi *noise* pada citra, standarisasi ukuran dan format citra, dan menyoroti fitur penting dalam citra. Berikut adalah tahapan-tahapan utamanya:

1. Resizing Image (mengubah ukuran gambar)

Supaya input gambar yang diterima oleh model memiliki ukuran yang konsisten.

Ukuran paling umum digunakan adalah 224×224 piksel.

2. Normalization

Normalisasi mengubah nilai piksel ke rentang tertentu, biasanya antara 0 dan 1, untuk mempercepat proses pelatihan model.

3. Grayscale Conversion

Jika warna tidak relevan untuk tugas, seperti mendeteksi tepi, gambar dapat dikonversi ke hitam-putih (grayscale).

4. Noise Reduction

Untuk mengurangi noise atau detail kecil yang tidak relevan sehingga merusak kualitas citra. Biasanya, teknik seperti Gaussian Blur sering digunakan dalam tahap ini.


5. Cropping

Agar model lebih fokus pada objek yang akan kita klasifikasi/deteksi, kita dapat memotong gambar yang tidak relevan dengan objek,

6. Image Augmentation

Kita dapat menambahkan data citra tanpa harus *collecting data* secara manual. Dengan augmentasi gambar, teknik dasar yang bisa kita lakukan adalah memberikan *horizontal & vertical flipping, rotation, cropping, shearing*, dsb., pada citra. Biasanya teknik ini dilakukan ketika melatih model, sehingga model dapat memberikan hasil yang lebih baik ketimbang tanpa melakukan augmentasi gambar.

B. Klasifikasi Citra Menggunakan CNN



CNN adalah salah satu jenis jaringan saraf tiruan (Convolutional Neural Network) yang dirancang khusus untuk menganalisis data yang memiliki struktur grid seperti gambar. CNN sangat efektif untuk tugas seperti klasifikasi gambar, deteksi objek, segmentasi citra, dan lain-lain. CNN memiliki komponen utama diantaranya:

- **Convolutional Layer (Lapisan Konvolusi)** untuk mengekstrak fitur dari gambar, seperti tepi, pola, atau tekstur. Contoh, jika kamu punya gambar wajah, lapisan konvolusi mungkin mengenali tepi mata, hidung, atau bibir.
- **ReLU (Rectified Linear Unit)** adalah fungsi aktivasi yang memastikan hanya nilai positif yang diteruskan, membantu model belajar lebih cepat dan menghindari masalah seperti gradient vanishing. Jika hasil konvolusi negatif, akan diubah menjadi 0, sementara nilai positif tetap diteruskan.
- **Pooling Layer (Lapisan Pooling)** untuk mengurangi ukuran fitur sambil mempertahankan informasi penting supaya mengurangi kompleksitas komputasi dan risiko *overfitting*. Layer ini dibagi menjadi dua yaitu *Max Pooling* dan *Average Pooling*.
- **Fully Connected Layer (Lapisan Terkoneksi Penuh)** lapisan ini menghubungkan semua neuron dan menghasilkan prediksi akhir. Contohnya, untuk klasifikasi gambar anjing atau kucing, lapisan ini memberikan output probabilitas untuk setiap kategori.

LATIHAN PRAKTIKUM

Gunakan data tabular berikut: [dataset](#). Kemudian lakukan proses preprocessing data sesuai kebutuhan dan tentukan target kelas untuk dilakukan klasifikasi. Gunakan algoritma klasifikasi apa saja untuk melakukan klasifikasi target kelas. Terakhir lakukan evaluasi hasil klasifikasinya. **(10 point)**

TUGAS

TUGAS 1 - DATA TEKS

NIM GENAP (0,2,4,6,8): [dataset genap](#)

NIM GANJIL (1,3,5,7,9): [dataset ganjil](#)

Lakukan klasifikasi (dari data cleaning sampai hasil akhir) dataset diatas berdasarkan algoritma yang sudah disebutkan di materi (bebas mau pakai algoritma yang mana saja). Kemudian, lakukan evaluasi akhir (akurasi minimal 78%). Buat section untuk masing-masing tahapan agar lebih rapi dan mudah dinilai oleh asisten. **(20 point)**

TUGAS 2 - DATA CITRA

NIM GENAP: [dataset genap](#)

NIM GANJIL: [dataset ganjil](#)

Gunakan **algoritma CNN** untuk mengklasifikasikan data citra berdasarkan jenisnya (akurasi minimal 75%). Buat section untuk masing-masing tahapan agar lebih rapi dan mudah dinilai oleh asisten. **(20 point)**

Apabila tidak sesuai dengan kriteria tugas dan source code persis/mirip dengan praktikan lain, maka akan dilakukan pengurangan nilai bahkan nilai maksimal D.

KRITERIA & DETAIL PENILAIAN

Detail	Bobot Nilai
Pemahaman Materi dan Ketepatan Jawaban	50
Tugas 1	20
Tugas 2	20
Latihan Praktikum	10