

VERSION 1.0
29 JANUARI 2025



[PENGGALIAN DATA]

MODUL 5 - CLUSTERING

DISUSUN OLEH:
ALVIYA LAELA LESTARI
KIARA AZZAHRA

DIAUDIT OLEH:
YUFIS AZHAR, S.KOM, M.KOM

LAB. INFORMATIKA
UNIVERSITAS MUHAMMADIYAH MALANG

[PENGALIAN DATA]

PERSIAPAN MATERI

Praktikan mempelajari teknik clustering

TUJUAN

1. Mahasiswa mampu memahami algoritma K-Means untuk Clustering
2. Mahasiswa mampu memahami algoritma DBSCAN untuk Clustering

PERSIAPAN SOFTWARE/APLIKASI

1. Hardware
 - Laptop/Komputer
2. Software (Pilih salah satu)
 - Visual Studio Code, Google Collaboratory, PyCharm, Jupyter Notebook
3. Tutorial
 - Menggunakan Google Colab :
https://youtu.be/tpDjhSzJor4?si=bFjSP_mf3oB5x520
 - Menggunakan Jupyter di VS Code :
<https://youtu.be/HOg13z1w1A?si=RhEY2QY5bir-dzEH>
 - Menggunakan Jupyter Notebook :
https://youtu.be/HQaCF2F_MR0?si=k6ubuGuCg-VS0tQe
 - Instal Anaconda : https://youtu.be/XyudQ3B3OWI?si=7qugN_vTxAM30qDt
4. Source Code:
<https://colab.research.google.com/drive/1zoQ7ge4V4TA9HxEXB8wJnWRd5wc7AL0n?usp=sharing>


Clustering adalah teknik dalam machine learning yang digunakan untuk mengelompokkan data ke dalam beberapa grup berdasarkan kemiripan atau kedekatan karakteristik. Metode ini termasuk dalam unsupervised learning karena tidak memerlukan label untuk memisahkan data.

Clustering memiliki berbagai aplikasi seperti segmentasi pelanggan, analisis pola, pengenalan gambar, dan pengelompokan dokumen. Dalam clustering, tujuan utama adalah meminimalkan jarak antar data dalam satu kelompok (intra-cluster) dan memaksimalkan jarak antar kelompok (inter-cluster).

1. K-Means Clustering

K-Means clustering adalah teknik yang digunakan untuk mengatur data ke dalam kelompok berdasarkan kesamaannya. Misalnya, online shop menggunakan K-Means untuk mengelompokkan pelanggan berdasarkan frekuensi pembelian dan pengeluaran, dengan menciptakan segmen seperti 'Pembeli Hemat', 'Pembeli Sering', dan 'Pembeli Besar' untuk pemasaran yang dipersonalisasi.

Algoritma ini bekerja dengan terlebih dahulu memilih beberapa titik pusat yang disebut centroid secara acak dan setiap titik data kemudian ditetapkan ke centroid terdekat yang membentuk klaster. Setelah semua titik ditetapkan ke klaster, centroid diperbarui dengan menemukan posisi rata-rata titik di setiap klaster. Proses ini berulang hingga centroid berhenti berubah dan membentuk klaster. Tujuan pengelompokan adalah untuk membagi titik data ke dalam klaster sehingga titik data yang serupa termasuk dalam kelompok yang sama.



1.1 Langkah Kerja Algoritma K-Means


- a. Tentukan jumlah cluster (K): Kita tentukan berapa banyak grup yang ingin dibuat. Misalnya, kita ingin mengelompokkan pelanggan menjadi 3 kelompok, maka $K = 3$.
- b. Inisialisasi Centroid secara acak: Centroid adalah titik pusat setiap kelompok. Kita pilih beberapa titik acak sebagai centroid pertama kali.
- c. Kelompokkan data: Setiap titik data (misalnya, pelanggan) akan dikelompokkan ke cluster yang centroid-nya paling dekat. Daya tariknya adalah bahwa titik data yang lebih mirip akan dikelompokkan bersama.
- d. Update centroid: Setelah semua data dikelompokkan, kita perbarui posisi centroid dengan cara menghitung rata-rata posisi data dalam kelompok tersebut.
- e. Ulangi langkah 3 dan 4: Proses ini diulang beberapa kali hingga posisi centroid tidak berubah lagi atau kita mencapai batas iterasi yang telah ditentukan.

1.2 Menentukan Nilai K yang Tepat

Meskipun K-Means bekerja dengan baik pada dataset training, penting untuk diingat bahwa kelemahan K-Means adalah kita harus menentukan jumlah cluster K, sebelum kita tahu bahwa nilai K sudah optimal. Jumlah cluster yang akan dipilih tidak selalu jelas dalam aplikasi dunia nyata, terutama jika kita bekerja dengan dataset berdimensi tinggi.

a. Metode Siku (Elbow)

Metode ini adalah sebuah pendekatan yang digunakan dalam analisis clustering untuk menentukan jumlah optimal dari cluster dalam data. Metode ini mencari titik dimana penurunan inersia mulai melambat, membentuk grafik yang menyerupai bentuk siku. Jika terdapat sudut atau penurunan dalam grafik, maka nilai cluster tersebut dapat dianggap yang terbaik.



b. Metode Silhouette Score


Silhouette score adalah metrik yang digunakan untuk mengevaluasi seberapa baik hasil clustering dalam clustering data. Skor ini berkisar dari -1 hingga 1, di mana nilai yang lebih tinggi menunjukkan hasil clustering yang lebih baik. Nilai dihitung dengan mengukur kemiripan setiap titik data dengan cluster yang dimilikinya dan seberapa berbedanya dengan cluster lain.

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Skor Silhouette	Kategori
$0,7 < skor \leq 1$	Strong Structure
$0,5 < skor \leq 0,7$	Medium Structure
$0,25 < skor \leq 0,5$	Weak Structure
$skor \leq 0,25$	No Structure

c. Metode Gap Statistics

Gap Statistic merupakan metode untuk menduga kelompok optimum pada analisis cluster. Gap ini dihasilkan dari membandingkan variasi antara data asli dan data acak. Nilai gap yang tinggi menunjukkan jumlah cluster yang optimal. Hal ini membantu kita memahami apakah pola yang kita lihat dalam data benar-benar bermakna atau hanya kebetulan.




Dalam gambar tersebut, nilai K optimal berdasarkan gap yang diperoleh adalah 3.

2. DBSCAN Clustering

Density-Based Spatial Clustering of Applications with Noise (DBSCAN) adalah algoritma clustering berbasis densitas yang mengelompokkan titik-titik data yang berdekatan dan menandai outlier sebagai noise berdasarkan kepadatannya di ruang fitur.

Tidak seperti K-Means atau clustering yang bersifat hierarkis lain yang mengasumsikan cluster bersifat kompak dan bulat, DBSCAN unggul dalam menangani ketidakteraturan data di dunia nyata seperti:

- Cluster berbentuk sembarangan: Cluster dapat berbentuk apa saja, tidak hanya melingkar atau cembung.
- Noise dan Outlier: Secara efektif mengidentifikasi dan menangani noise points tanpa melemparnya ke cluster lain.



Langkah Kerja Algoritma DBSCAN:

- Tentukan parameter eps (radius) dan min_samples (jumlah minimum poin dalam radius).
- Mulai dengan titik data awal, cek apakah jumlah titik dalam radius eps memenuhi min_samples.
 - Jika ya, jadikan titik ini sebagai titik inti dan bentuk cluster.
 - Jika tidak, tandai sebagai noise atau outlier.
- Ulangi proses untuk semua titik sampai tidak ada lagi titik yang dapat dimasukkan ke cluster.

CODELAB

Codelab dikerjakan di Google Collab masing-masing!

[Dataset Codelab](#)

Code di bawah ini merupakan kerangka pengerjaan untuk clustering. Perbaiki dan lengkapi agar bisa berjalan tanpa error.

1. Import library yang dibutuhkan.

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.preprocessing import ...
from sklearn.cluster import ...
from sklearn.compose import ...
```

2. Import dataset.

```
df = pd.read_csv('your_file_path.csv')
```

3. Lakukan EDA secukupnya.

4. Lakukan visualisasi data.

5. Lakukan pre-processing data.

```
# Tips: Gunakan pd.get_dummies() untuk one hot encoding
df_encoded = pd.get_dummies(df, columns=['...'])

scaler = MinMaxScaler()
df_encoded[['...', '...', '...']] = scaler.fit_transform(df_encoded[['...', '...', '...']])
```

6. Terapkan K-Means.

```
# Gunakan metode Elbow untuk menentukan jumlah kluster yang ideal
wcss = []
for i in range(1, 11):
    kmeans = KMeans(n_clusters=i, init='k-means++', random_state=42)
    kmeans.fit(df_encoded[['...', '...']])
    wcss.append(kmeans.inertia_)

plt.plot(range(1, 11), wcss)
plt.title('Metode Elbow')
plt.xlabel('Jumlah Kluster')
plt.ylabel('WCSS')
plt.show()

#Lanjutkan proses clustering
```

7. Interpretasikan cluster.

Setelah menentukan jumlah cluster, lakukan analisis untuk memahami karakteristik dari setiap kluster.

TUGAS

NIM GANJIL

[Dataset Tugas Ganjil](#)

Kalian akan melakukan analisis clustering pada dataset untuk mengelompokkan pasien berdasarkan karakteristik mereka. Gunakan metode K-Means dan DBSCAN untuk menemukan pola dalam data.

1. Data Preprocessing:

- Unduh dan muat dataset ke dalam Python menggunakan pandas.
- Lakukan eksplorasi dataset dengan menampilkan 5 data pertama dan informasi tipe data pada setiap kolom.
- Periksa apakah ada missing values pada dataset dan tangani dengan strategi yang sesuai.
- Lakukan encoding pada variabel kategorikal yang diperlukan.
- Lakukan normalisasi pada fitur numerik yang akan digunakan dalam clustering.

2. K-Means Clustering:

- Gunakan metode Elbow, Silhouette Score, dan Gap Statistics untuk menentukan jumlah cluster yang optimal (nilai K).
- Terapkan algoritma K-Means Clustering pada dataset dengan jumlah cluster yang telah ditentukan.
- Visualisasikan hasil clustering menggunakan scatter plot dengan dua fitur utama.
- Interpretasikan hasil clustering.

3. DBSCAN Clustering:

- Terapkan algoritma DBSCAN pada dataset dan tentukan parameter eps serta min_samples yang sesuai dengan menggunakan pendekatan yang sistematis.
- Visualisasikan hasil clustering menggunakan scatter plot.
- Bandingkan hasil clustering antara K-Means dan DBSCAN. Jelaskan kelebihan dan kekurangan masing-masing metode dalam konteks dataset ini.

NIM GENAP

[Dataset Tugas Genap](#)

Kalian diminta untuk melakukan analisis clustering pada dataset. Tujuan dari analisis ini adalah untuk mengelompokkan individu berdasarkan karakteristik mereka dan mengidentifikasi pola yang mungkin terkait dengan risiko serangan jantung.

1. Data Preprocessing:

- Unduh dan muat dataset ke dalam Python menggunakan pandas.
- Lakukan eksplorasi dataset dengan menampilkan 5 data pertama dan informasi tipe data pada setiap kolom.
- Periksa apakah ada missing values pada dataset dan tangani dengan strategi yang sesuai.
- Lakukan encoding pada variabel kategorikal yang diperlukan.
- Lakukan normalisasi pada fitur numerik yang akan digunakan dalam clustering.

2. K-Means Clustering:

- Gunakan metode Elbow, Silhouette Score, dan Gap Statistics untuk menentukan jumlah cluster yang optimal (nilai K).
- Terapkan algoritma K-Means Clustering pada dataset dengan jumlah cluster yang telah ditentukan.
- Visualisasikan hasil clustering menggunakan scatter plot dengan dua fitur utama.
- Interpretasikan hasil clustering.

3. DBSCAN Clustering:

- Terapkan algoritma DBSCAN pada dataset dan tentukan parameter eps serta min_samples yang sesuai dengan menggunakan pendekatan yang sistematis.
- Visualisasikan hasil clustering menggunakan scatter plot.
- Bandingkan hasil clustering antara K-Means dan DBSCAN. Jelaskan kelebihan dan kekurangan masing-masing metode dalam konteks dataset ini.

PERINGATAN: Terdapat Kemiripan Source Code Yang Signifikan Dengan Praktikan Lain, Nilai Maksimal D

KRITERIA & DETAIL PENILAIAN

Detail		Bobot Nilai
Codelab		10
Tugas	Data Pre-processing	15
	K-Means Clustering	15
	DBSCAN Clustering	15
Pemahaman Materi & Ketepatan Jawaban		45